

Segmentación de la región acetoblanca en colposcopías del cérvix

Acetowhite region segmentation in cervix colposcopies

Saúl Olivera Perdomo¹, Marta L. Baguer Díaz-Romañach^{1*}, Damian Valdés Santiago¹, Águeda Santana Martínez²

Resumen La colposcopia es un procedimiento ginecológico de diagnóstico del cáncer cérvico uterino. La región acetoblanca es una zona del cérvix que adquiere o acentúa coloración blanca tras aplicársele una solución de ácido acético. Esta región es un indicador de lesión severa sobre este epitelio. En esta investigación se proponen estrategias para preprocesar las imágenes colposcópicas, detectar de forma automática el área cervical y segmentar la región acetoblanca combinando algoritmos de agrupamiento y Morfología Matemática en el espacio de colores *Lab*. Se creó una base de imágenes colposcópicas cubanas y se propusieron dos medidas de calidad cuantitativas para evaluar la eficacia de los algoritmos. En la experimentación se compararon cuatro algoritmos de agrupamiento y un método que combina umbralización con operaciones morfológicas. El agrupamiento mediante Modelo de Mezclas Gaussianas, estimando parámetros con el algoritmo Esperanza-Maximización y *Mini-batch k-means*, alcanzó en promedio una efectividad del 87% en la detección de la región acetoblanca, validada por la evaluación cualitativa realizada por la Dra. Águeda Santana. Los resultados reflejaron la importancia de la eliminación de regiones especulares propias de las imágenes adquiridas. Además, se propuso un algoritmo basado en agrupamiento para detectar diferentes niveles de blanco en una región acetoblanca. Estas zonas suelen ser un indicador de cáncer y pueden usarse como marcadores de biopsia que confirmen o no el diagnóstico.

Abstract Colposcopy is a gynecological procedure for cervix cancer diagnosis. The acetowhite region is a cervix area that acquire or increase its white coloring after the application of an acetic acid solution. That region is a sign of a severe lesion on that epithelium. In this paper we propose strategies for preprocessing acquired images, detecting automatically cervical area and segmenting acetowhite region using clustering algorithms and Mathematical Morphology within *Lab* color space. We have created a Cuban colposcopic image dataset and proposed two quantitative quality measures for evaluating the algorithm performance. In the experimentation we compared four clustering algorithms and a method based on thresholding and morphological operations. The clustering using Gaussian Mixture Model with Expectation–Maximization algorithm and *Mini-batch k-means* for parameters estimation, showed an efficiency average of 87%. This result was also validated by the physician Águeda Santana's qualitative evaluation. Results highlighted the importance of specular reflection's removal that appear in acquired images. We presented also a clustering-based algorithm for detecting different white levels within an acetowhite region. These areas could be a sign of cancer as well as biopsy markers to confirm the diagnosis.

Palabras Clave

Colposcopia del cérvix — Segmentación — Región acetoblanca — Agrupamiento — Morfología Matemática

¹Departamento de Matemática Aplicada, Facultad de Matemática y Computación, Universidad de La Habana, Cuba
s.olivera@lab.matcom.uh.cu, mbaguer@matcom.uh.cu, dvs89cs@gmail.com

²Hospital Materno de 10 de Octubre, La Habana, Cuba, aguesam@infomed.sld.cu

*Autor para Correspondencia

Introducción

El cáncer de cuello de útero, cáncer cervical o carcinoma de cérvix es el segundo tipo de cáncer más común en las mujeres a escala mundial y constituye aproximadamente el 25 %

de los cánceres ginecológicos [1]. Según GLOBOCAN¹, en el mundo se producen anualmente cerca de 500 000 nuevos casos de este tipo de cáncer que provoca la muerte de alrede-

¹<http://globocan.iarc.fr>

dor de 270 000 mujeres, de estas más del 80 % ocurre en los países en vías de desarrollo.

En Cuba la mortalidad por esta afección ha venido incrementándose en los últimos treinta años. Se ha pronosticado que las muertes causadas por esta enfermedad deben aumentar en un 25 % en los siguientes diez años [2].

El cáncer cérvico uterino aparece en los tejidos que se encuentran en la parte baja del útero y se expande hacia el epitelio exocervical. Si las lesiones en estos tejidos son detectadas tempranamente, la probabilidad de una cura total es muy alta.

El índice de mortalidad por cáncer cérvico uterino se redujo dramáticamente desde la introducción de la prueba de Papanicolaú [3]. Sin embargo, este examen no es exacto pues depende estrechamente de los lugares en que se toman las muestras. Esto motivó el uso del Colposcopio² para realizar inspecciones visuales sobre el útero.

En la actualidad se comercializan los colposcopios digitales con los cuales se pueden tomar imágenes y videos con un mayor contraste y definición. Esto ha posibilitado el uso de programas informáticos como herramientas de asesoramiento para el diagnóstico de los médicos. En Cuba, la empresa TecnoSUMA® se dedica al desarrollo de dispositivos tecnológicos de diagnóstico médico como el videocolposcopio digital SUMASCOPE.

Entre los agentes de contraste más usados en colposcopía está la solución de ácido acético entre el 3–5 %, la cual resalta regiones sobre el epitelio exocervical que toman un color blancuzco (región acetoblanca).

La aparición de una región acetoblanca indica que en ese epitelio existe un incremento de la actividad celular, aunque no se observen vasos atípicos. Rasgos característicos de esta región pueden ser la intensidad del color blanco, la textura del epitelio sobre dicha zona o el tipo de blanco (si es perlado o no). Estas son características que deben ser consideradas por los especialistas para proporcionar un diagnóstico clínico [4].

En la literatura existen numerosas referencias a sistemas automáticos para el apoyo al diagnóstico, sin embargo, en la revisión realizada se encontraron pocos artículos dedicados especialmente a segmentar la región acetoblanca. Específicamente para las imágenes colposcópicas esta no es una tarea trivial ya que la luminosidad en las imágenes no es uniforme, pueden aparecer regiones especulares o de brillo y los patrones de textura de las lesiones no muestran estructuras regulares. Otro aspecto que complejiza el problema es que los bordes de la región acetoblanca, en muchos de los casos, no forman estructuras cerradas o son difusos.

En [5] y [6] se utiliza un clasificador k vecinos más cercanos, $k - NN$ (k -nearest neighbors, por sus siglas en inglés) para diferenciar las imágenes colposcópicas normales de las que no lo son. En [7] se aplican una serie de procesamientos

²Un Colposcopio es un telescopio binocular de enfoque próximo que permite al médico ver con detalle regiones anómalas del cuello uterino a través de la vagina. El primer Colposcopio creado en 1925 se debe a Hans Hinselman, médico alemán.

basados en el uso de las imágenes antes y después de aplicar el ácido acético y luego se utilizan Máquinas de Soporte Vectorial, SVM (*Support Vector Machines*, por sus siglas en inglés) para identificar las regiones cervicales anómalas. En [8] se usa aprendizaje supervisado para segmentar la región acetoblanca. La no disponibilidad de una base de imágenes colposcópicas marcada impidió el uso de métodos del aprendizaje supervisado y la comparación con investigaciones semejantes.

En [9] se establecen una serie de pasos para el análisis de las imágenes colposcópicas. Primeramente, se realiza un preprocesamiento con el objetivo de eliminar el brillo ocasionado por la luz y normalizar los colores y la luminosidad espacial de la imagen. Luego se hace un análisis de la anatomía con el objetivo de dividir la imagen colposcópica en las regiones: cérvix, orificio cervical externo y la columnar³ y como un paso adicional también se extraen texturas. Finalmente se identifica la región acetoblanca mediante la combinación de la información obtenida en los pasos anteriores y aplicando varios tipos de métodos de agrupamiento.

En [10] se utiliza la Morfología Matemática para detectar la región acetoblanca. En principio se asume que la imagen de entrada no presenta regiones de brillo y se pasa directamente a detectar la región de interés, ROI (*Region of Interest*, por sus siglas en inglés). Este proceso se realiza mediante el uso de un clasificador que distingue los colores del cérvix. Seguidamente se utiliza un algoritmo de segmentación basado en la Transformada Watershed que localiza los bordes del cérvix. A continuación, se mejora el contraste de la imagen, se elimina el ruido y se realzan los bordes. Luego, usando un algoritmo basado en Watershed se divide la ROI en superpíxeles y posteriormente se agrupan según el promedio de color de cada uno.

En [11] se asume que la región cervical está libre de brillo y se detectan sobre esta área tres tipos de regiones: la región escamosa, la columnar y la acetoblanca. Para lograrlo, se extrae por cada píxel de la imagen un rasgo que represente su nivel de textura. Luego se modela la imagen representada en el espacio de colores *Lab* junto con el vector de características extraído anteriormente mediante una mezcla de tres funciones gaussianas. Finalmente, cada píxel de la imagen es asociado a la gaussiana que mejor lo represente, dividiendo así el área en las tres regiones mencionadas con anterioridad.

Una vez estudiada la literatura disponible sobre el tema y tomando en consideración las propiedades de las imágenes colposcópicas que se tienen, se dividió la segmentación de la región acetoblanca en tres pasos: preprocesamiento de la imagen para mejorar su calidad, detección de la región cervical y segmentación de la región acetoblanca dentro de la región cervical. Algunos autores introducen uno o varios pasos intermedios donde se restringe la ROI como es el caso de Li et al. [9].

Para mejorar la calidad de la imagen se elimina el ruido

³La región columnar es la unión del epitelio cilíndrico con el epitelio escamoso y se suele localizar generalmente a continuación del orificio cervical externo.

mediante el uso del filtro gaussiano y el filtro de mediana [12] y se proponen algunos algoritmos para mejorar la iluminación. Para determinar las regiones del cérvix y acetoblanca se implementaron dos algoritmos, uno basado en agrupamiento y el otro basado en Umbralización y Morfología Matemática (UMA), ambos asumen que la región acetoblanca se encuentra cercana al centro. Esto plantea un problema adicional, puesto que en muchas de las imágenes colposcópicas aquí utilizadas tal región puede encontrarse en una esquina, a un lado, en toda la imagen, o estar incompleta.

La estructura del artículo es la siguiente. En la sección 1 se exponen los algoritmos de agrupamiento utilizados. En la sección 2 se describe la etapa del preprocesamiento que incluye la eliminación de la región especular y la corrección y eliminación del ruido. En la sección 3 se expone cómo se detectó la ROI mediante agrupamiento y Morfología Matemática. La sección 4 describe el uso de la Morfología Matemática y el Modelo de Mezclas Gaussianas para la detección de la región acetoblanca. La construcción de la base de datos colposcópica, las medidas de evaluación cuantitativa y el software utilizado se describen en las secciones 5, 6 y 7 respectivamente. En la sección 8 se presentan y discuten los resultados y en la sección 9 se brindan las conclusiones de esta investigación.

1. Métodos de agrupamiento

Los métodos de agrupamiento dividen los datos en subconjuntos de tal manera que las instancias similares son agrupadas mientras que instancias diferentes pertenecen a grupos distintos [13]. En esta investigación se consideraron como algoritmos de agrupamiento *k-means*, *Mini-batch k-means*, Modelos de Mezclas Gaussianas y Modelo de Mezclas Gaussianas por Inferencia Bayesiana.

k-means partitiona los datos en *k* grupos representados por sus centros. El centro de cada grupo es calculado como el promedio de todas las instancias que pertenecen a dicho grupo. El algoritmo comienza con un conjunto inicial de centros, escogidos al azar o de acuerdo a alguna heurística. Por iteración, cada instancia es asignada al centro más cercano según la distancia euclídea, y luego los centros son recalculados [13]. Como condiciones de parada de *k-means* pueden considerarse el número máximo de iteraciones o que los centros no cambien entre una iteración y la siguiente.

Mini-batch k-means es una variante del algoritmo *k-means* que usa subconjuntos aleatorios del conjunto de datos de entrada para calcular los centroides. Estos subconjuntos se denominan *mini-batch* y tienen la propiedad de poseer un tamaño fijo que se introduce como parámetro. Aunque su convergencia es mucho más rápida que la de *k-means*, la calidad de los resultados, medida por la suma de las distancias de cada punto a su centroide más cercano, no es tan buena como la de *k-means* [14].

Los Modelos de Mezclas Gaussianas, GMM (*Gaussian Mixture Models*, por sus siglas en inglés) pueden ser utilizados para la implementación de métodos de agrupamiento

asociando cada instancia de los datos a la gaussiana que mejor la representa. Los GMM se basan en la suposición de que cada grupo *d*-dimensional en un conjunto de datos puede ser modelado como una distribución normal multivariada (gaussiana). Por consiguiente, el conjunto de datos completo podrá ser modelado como una mezcla de cada una de estas gaussianas. Para reducir la complejidad de las operaciones matemáticas del modelo, se suele usar el logaritmo de la verosimilitud para un conjunto de observaciones dado. La estimación de máxima verosimilitud no es una tarea trivial, por tanto, es necesaria la utilización de algún método para la determinación del conjunto óptimo de parámetros [15].

Una de las elecciones más usuales para obtener estimaciones de máxima verosimilitud para los parámetros de la mezcla es el algoritmo Esperanza–Maximización (EM) [16, 17]. El algoritmo EM genera una secuencia de estimaciones del conjunto de parámetros alternando los pasos E (Esperanza) y M (Maximización) hasta lograr la convergencia, generalmente un límite de iteraciones a realizar. Las cuestiones relativas a la convergencia del método han sido ampliamente estudiadas [17, 18].

En el Paso E se asume una estimación inicial de los parámetros en cuestión, por lo que esto supone una tarea adicional ya que el éxito del algoritmo EM depende en gran medida de los valores iniciales del conjunto de parámetros. La mayoría de las soluciones propuestas incluyen estrategias como por ejemplo la utilización de varias inicializaciones aleatorias y la selección de la que concluye con un mayor valor de verosimilitud, o la realización de un agrupamiento previo con alguno de los métodos existentes para ello [17, 19]. En este artículo se considera que, por defecto, los parámetros de la mezcla son estimados mediante EM el cual usa *k-means* para inicializar. Al GMM que utiliza *Mini-batch k-means* en EM se le denominará CustomGMM.

Un Modelo de Mezclas Gaussianas por Inferencia Bayesiana, VBGMM (*Variation Bayesian Gaussian Mixture Model*, por sus siglas en inglés) es una variante del GMM que implementa el algoritmo Inferencia Variacional para estimar los parámetros del modelo. El algoritmo Inferencia Variacional es una extensión del algoritmo EM y se basa en el mismo principio, es decir, ambos son métodos iterativos y alternan entre encontrar las probabilidades de cada instancia de ser generada por cada núcleo y maximizar. A diferencia de EM este método agrega regulaciones mediante la integración de información de la distribución de probabilidad [20].

2. Preprocesamiento de la imagen colposcópica

Las imágenes colposcópicas utilizadas poseen características peculiares. Dichas imágenes presentan regiones de brillo o especulares debido a las características húmedas propias de los tejidos del cuello uterino y de la aplicación de las diferentes soluciones. También poseen ruido y pueden tener una mala distribución de la iluminación. Además, la imagen

colposcópica puede mostrar otras partes de la vagina o del espéculo diferentes de la región del cérvix. Por estas razones se decidió aplicar un preprocesamiento con el objetivo de aumentar la calidad de la imagen colposcópica y de esta forma mejorar el resultado de los algoritmos de segmentación.

Tomando en consideración que los algoritmos de segmentación que se proponen más adelante trabajan solo con algunos canales de la imagen en el espacio de colores *Lab*, procesamos cada canal considerándolo una imagen en escala de grises.

2.1 Eliminación de la región especular

Una región especular es una zona brillante producto del reflejo de la luz de la cámara del colposcopio. Estas regiones afectan el resultado de los algoritmos de segmentación por lo que su eliminación es muy necesaria. Para la eliminación de la región especular se utilizó la propuesta de Palmer que implementa tres algoritmos para obtener las máscaras de la región especular y tres algoritmos de restauración de los píxeles [21]. Se experimentó con diferentes valores de los parámetros y se eligió la variante que obtuvo mejores resultados visuales.

2.2 Corrección de la iluminación

Una vez eliminada la región especular se prosigue a la corrección de la iluminación. Dicha corrección consiste en tratar de aclarar los píxeles más oscuros de la imagen y dejar los más claros con su iluminación. Una relajación a lo anterior sería efectuar una mayor aclaración a los píxeles más oscuros y una menor aclaración a los menos oscuros. Sea p un píxel de I_{gris} tal que $I_{gris}(p) = x$ y sea q otro píxel de I_{gris} tal que $I_{gris}(q) = y$ de tal forma que $p \neq q$ y $x > y$, sea x^c, y^c el complemento de x y de y respectivamente. Tomando en consideración que $0 \leq x, y \leq 255$ entonces $x^c = 255 - x$ y $y^c = 255 - y$, por tanto si $x > y$ entonces $y^c > x^c$. Luego, si x es la intensidad del píxel p más claro que q de intensidad y , entonces una solución propuesta al problema en cuestión sería sumarle a cada intensidad de cada píxel una fracción de su complemento, es decir, $x^c \cdot \rho$ donde $0 \leq \rho \leq 0,5$. Se puede observar que si $\rho = 0$ no se modificaría la imagen y para $\rho = 0,5$ se le sumaría a cada píxel la mitad de su complemento. Se decidió no sumar más de la mitad ya que cuando ρ tiende a uno entonces I_{gris} tiende a la imagen en blanco y por tanto no se obtienen buenos resultados.

Para la experimentación se propone aplicar también este procedimiento en el espacio de colores *Lab*.

2.3 Eliminación del ruido

Una vez eliminada la región especular y corregida la iluminación se procede a eliminar el ruido. Al no poseer información alguna del tipo de ruido, se utilizaron los filtros de mediana y gaussiano para su eliminación [12].

3. Detección de la ROI

La imagen colposcópica puede contener además del cuello uterino, información irrelevante tal como el espéculo, partes de la vagina, etc. Esta información puede provocar una mala

detección de la región acetoblanca. A continuación se propone extraer la ROI dentro de la imagen colposcópica y de esta forma eliminar toda información irrelevante. En este artículo la ROI se entiende como la región cervical pues solo en esta zona se puede encontrar algún epitelio acetoblanco.

Por otra parte, el espacio de colores *Lab* resume en sus canales a y b toda información de color, donde a indica la transición del color rojo al verde, un alto valor de a significa un color rojizo del píxel. Teniendo en cuenta que la región cervical es una región relativamente rosada que se encuentra localizada cercana al centro de la imagen, entonces sería intuitivo tomar los canales a de la imagen en *Lab*, y d (distancia de cada píxel al centro) y utilizar algún método de agrupamiento para formar dos grupos sobre el espacio (a, d) . Estos dos conjuntos se forman de modo que el grupo con mayores valores de a y menores valores de d represente a la región del cérvix. El canal d provee información espacial y permite la extracción de regiones continuas en el plano de la imagen, mientras que a es solo información del color.

En la literatura consultada en general se proponen ideas de este tipo [22, 23, 24, 25]. Lo único que diferencia unas ideas de otras es el método de agrupamiento que utilizan.

El algoritmo propuesto para la detección de la ROI convierte la imagen colposcópica RGB⁴ al espacio *Lab*, elimina el ruido en el canal a , calcula la distancia d de cada píxel al centro de la imagen y agrupa los píxeles en dos conglomerados según el vector (a, d) . Se asume que la ROI está formada por los píxeles del grupo que posee el menor promedio de la distancia d .

En la experimentación se pudo apreciar que el resultado del agrupamiento puede no adherirse a los bordes de la región del cérvix y de esta manera se excluyen partes que son de interés. Además, pueden quedar pequeñas regiones fuera de la máscara y pequeños huecos dentro de esta. Esto puede ser consecuencia del ruido y de los pequeños cambios de color que persisten en la imagen aún después de la aplicación de los filtros morfológicos. Para solucionar este problema se consideró añadir un parámetro $w \in [0, 1]$ para ponderar la distancia en el agrupamiento y usar operaciones morfológicas (Figura 1). Como paso final del algoritmo se aplican a la máscara las operaciones morfológicas erosión, dilatación y cierre con el objetivo de eliminar pequeñas regiones, suavizar los bordes y eliminar los huecos en la máscara.

Tras el uso de las operaciones morfológicas planteadas anteriormente, la máscara de la ROI está más ajustada al cérvix, pero todavía existen píxeles ruidosos. Por este motivo se propone un algoritmo para rectificarla.

El algoritmo propuesto para rectificar la ROI asume que la región cervical se encuentra localizada cerca del centro de la imagen. Además, teniendo en cuenta que esta región debería ocupar, alrededor o más de la mitad de la imagen, entonces lo más probable es que el centro de la imagen se encuentre dentro de la máscara de la región cervical [26, 21].

⁴RGB por sus siglas en inglés significa una imagen a color de tres canales rojo (R), verde (G) y azul (B).

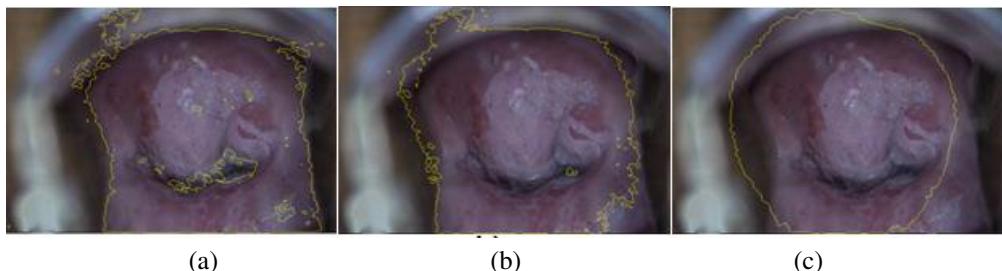


Figura 1. Resultados de aumentar el parámetro w en la detección de la región cervical: (a) $w = 0,06$, (b) $w = 0,21$ y (c) $w = 0,5$

Por tanto, la idea del algoritmo es primeramente rectificar los bordes de la ROI tomando de esta solamente los puntos que estén más cercanos al centro; para esto se trazan rectas desde el centro de la imagen hacia el borde de la misma y se conservan los puntos de dicha recta que coincidan con puntos que sean bordes de la máscara de la ROI. Luego se toma como punto del borde de la ROI solo el que está a menor distancia euclíadiana del centro. En la práctica, no se traza una recta por cada punto del borde de la imagen ya que esto es ineficiente, en lugar de hacer esto se decidió trazar una recta por cada intervalo de puntos en el sentido de las manecillas del reloj. Por ejemplo, se consideran intervalos de veinte puntos del borde de la imagen, y luego se une cada uno con su sucesor mediante una recta. El resultado de aplicar lo anterior es un borde cerrado que en su interior contiene a la región del cérvix. En el siguiente paso se obtiene la máscara que representa el interior de este borde mediante la Transformada Watershed tal como indica Del Risco [27], obteniendo de esta forma la máscara mostrada en la Figura 2.

4. Detección de la región acetoblanca

Una vez definida la ROI se pueden aplicar sobre esta los diferentes algoritmos para segmentar la región acetoblanca. Para detectar y analizar la región acetoblanca se tuvieron en cuenta dos ideas presentadas en [28]. Una de ellas basada en agrupamiento y la otra basada en UMA. Ambas técnicas fueron adaptadas para la identificación de varias intensidades de blanco en la propia región acetoblanca (multidetección).

4.1 Técnica basada en agrupamiento

Varios son los artículos que usan GMM con el objetivo de detectar la región acetoblanca [11, 23, 28]. GMM puede ser usado como método de agrupamiento. Basta estimar los parámetros de máxima verosimilitud con EM para la mezcla de las k gaussianas que representarán los k grupos en los que se desea dividir los datos.

La hipótesis en la cual se basan los artículos mencionados anteriormente es la siguiente. Una vez que la región especular es eliminada, así como toda información irrelevante, la imagen resultante queda formada por tres regiones predominantes: el epitelio columnar, el epitelio escamoso y la región acetoblanca. La región columnar es la que se encuentra inmediatamente alrededor del orificio cervical externo, es de un color rojizo y

se localiza aproximadamente cercana al centro de la imagen. La región acetoblanca (objetivo a segmentar) es la que se encuentra inmediatamente alrededor de la región columnar, esta tiene una apariencia blancuzca o de un rosado pálido y es usualmente la región más brillosa. La región restante es la escamosa la cual es de un rojizo que se encuentra entre el color de la región acetoblanca y el de la columnar. Basados en estas observaciones, se seleccionaron tres características para caracterizar la imagen a ser segmentada.

Para representar la diferencia de intensidades se toma el canal a de la imagen en el espacio de colores Lab , la diferencia de rojos es representada por el canal d de este mismo espacio y la distancia euclíadiana de cada píxel al centro de la imagen, d es usada para representar la diferencia en cuanto a orientación espacial. Al igual que en el procedimiento para hallar la ROI, la matriz d es multiplicada por un factor w donde $0 \leq w \leq 1$, el cual indica el peso de la distancia.

Para detectar la región acetoblanca se toma la imagen con la región especular ya eliminada, se convierte al espacio de color Lab , se elimina el ruido en los canales L y a mediante el algoritmo explicado previamente, se computan los valores L , a y d (distancia al centro) por cada píxel que pertenezca a la ROI y se aplica alguno de los métodos de agrupamiento planteados sobre el espacio tridimensional (L, a, d) con el objetivo de formar tres grupos. Luego, el grupo con mayores valores de L se asume que es el que representa la región acetoblanca. Finalmente, se aplican las operaciones morfológicas erosión y dilatación.

4.2 Técnica basada en Umbralización y Morfología Matemática

Otra de las técnicas reportada en la literatura está motivada por la forma en la que los médicos con experiencia dibujan el borde de la región acetoblanca [28]. Este método convierte la imagen representada en escala de grises en una imagen binaria mediante el uso del umbral de Otsu [29] seguido de una secuencia de operaciones morfológicas para finalmente obtener la región acetoblanca.

Este procedimiento asume que la imagen I_{rgb} de entrada no tiene regiones de brillo ni información irrelevante. Luego se procede a su conversión a escala de grises de la siguiente forma [28]:

$$I_{gris}(p) = 0,3 \cdot I_{rgb}^r(p) + 0,59 \cdot I_{rgb}^g(p) + 0,21 \cdot I_{rgb}^b(p) \quad (1)$$

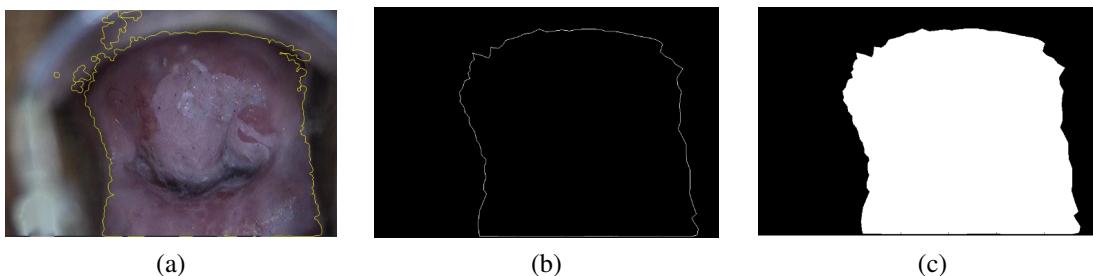


Figura 2. Fases en la detección de la ROI: (a) ROI obtenida por el algoritmo propuesto, (b) ROI obtenida después del proceso de rectificación y (c) Máscara de la ROI definitiva

El umbral global se calcula usando el método de Otsu [29] para transformar la imagen en escala de grises I_{gris} a una imagen binaria. El método Otsu produce un umbral tal que maximiza la separación entre las varianzas inter-clases e intra-clases [29] y de esta forma brinda una idea general sobre la localización de la región acetoblanca. Las regiones desconectadas de la región central son eliminadas usando erosión con un elemento estructurante cuadrado de 3×3 . Posteriormente el borde de la región acetoblanca es sometido a una secuencia de dilataciones usando cuatro elementos estructurantes lineales orientados en cuatro diferentes ángulos, 0, 45, 90 y 135 grados. Finalmente, con el objetivo de cerrar los posibles huecos dentro de la máscara, se aplica sobre esta una operación de cierre obteniendo de esta forma la región acetoblanca definitiva que dará el algoritmo como resultado.

5. Imágenes colposcópicas utilizadas

En este estudio se utilizaron 40 imágenes de cuello de útero tomadas a pacientes cubanas (debidamente codificadas) por la Dra. Águeda Santana en el Hospital Materno de 10 de Octubre.

Las imágenes utilizadas no aparecen clasificadas ni anotadas por lo que para evaluar los algoritmos la Dra. Santana realizó las anotaciones de las regiones cervical y acetoblanca (*ground truth*) con ayuda de un software implementado para este fin.

6. Medidas cuantitativas

Se diseñaron dos medidas de calidad, una para evaluar la detección de la región cervical o ROI y otra para la detección de la región acetoblanca. La idea general que se tuvo en cuenta para el diseño de cada una de estas fue repartir 100 puntos de la siguiente forma: 50 puntos para evaluar si todos los píxeles que están dentro de la región correspondiente se incluyen en la *ground truth* y los otros 50 puntos en evaluar si no se detectaron píxeles fuera de la región marcada por la especialista.

7. Software

Los algoritmos fueron implementados en el lenguaje de programación Python 2.7.6 [30]. Se utilizaron los módulos

NumPy 1.7.1 [31], SciPy 0.13.0 [32], Matplotlib 1.3.1 [33], skimage 0.9.3 [34], sklearn 0.14.1 [35], OpenCV 2.4.6.0 [36] y PyQt.

8. Resultados y discusión

8.1 Efecto de la eliminación de la región especular en la detección de la región acetoblanca

En la Figura 3 se presentan algunos resultados de aplicar el algoritmo de agrupamiento para detectar la región acetoblanca a varias imágenes antes y después de eliminar la región especular. Cuando no se elimina la región especular no se logra detectar con efectividad la región acetoblanca. Esto se debe a que dicha región está formada por píxeles de alta intensidad de gris, que debieran formar la región acetoblanca en una imagen sin brillo.

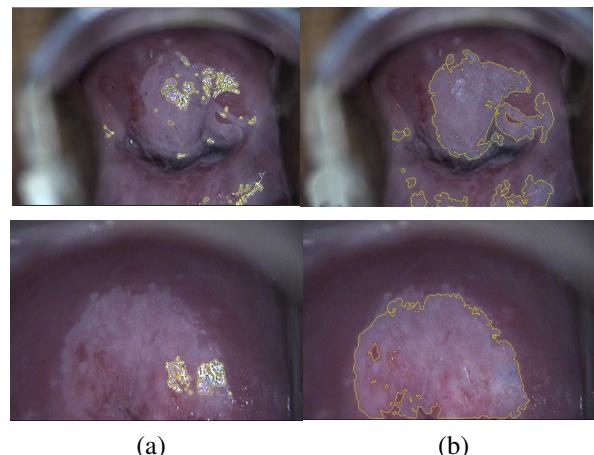


Figura 3. Efecto de la eliminación de la región especular para la detección de la región acetoblanca mediante CustomGMM: (a) Resultado sin eliminar la región especular, (b) Resultado después de eliminar la región especular

En la Figura 4 se presentan algunos resultados de aplicar el algoritmo basado en UMA a varias imágenes antes y después de eliminar la región especular. El experimento anterior nos permite concluir que en imágenes con región especular existe una alta probabilidad de que los algoritmos para detectar la región acetoblanca no funcionen correctamente.

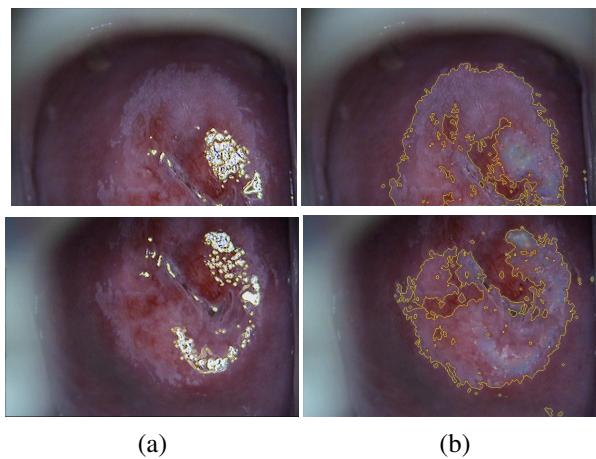


Figura 4. Efecto de la eliminación de la región especular para la detección de la región acetoblanca mediante UMA: (a) Resultado sin eliminar la región especular, (b) Resultado después de eliminar la región especular

8.2 Importancia de la selección previa de la ROI

Uno de los primeros pasos en la detección de la región acetoblanca es la selección de una ROI adecuada donde los algoritmos deben detectar la región acetoblanca. En la Figura 5 se presentan los resultados del algoritmo basado en agrupamiento donde se detecta o no previamente la región cervical. Como se puede apreciar, en ninguna de las imágenes anteriores se logra detectar correctamente la región acetoblanca si es aplicado sobre toda la imagen. Sin embargo, cuando se aplica solo sobre la región cervical en la misma imagen este obtienen mejores resultados.

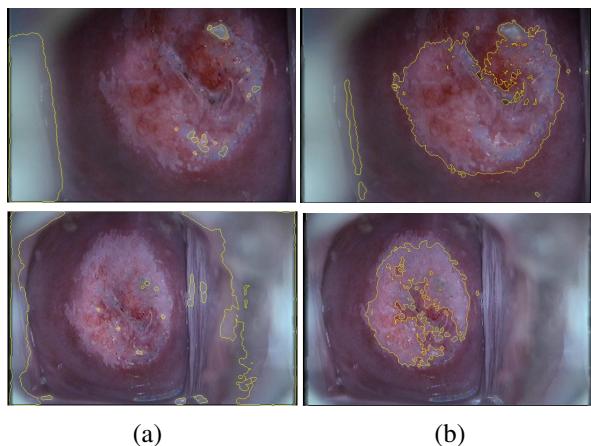


Figura 5. Efecto de la selección de la región cervical para la detección de la región acetoblanca mediante CustomGMM: (a) Resultado sobre toda la imagen, (b) Resultado sobre la región cervical elegida

En la Figura 6 se presenta el mismo experimento previo pero esta vez con el algoritmo basado en UMA. Nuevamente, los resultados no son buenos cuando se aplica a la imagen completa, pero la efectividad de esta mejora sustancialmente cuando se restringe a la región cervical.

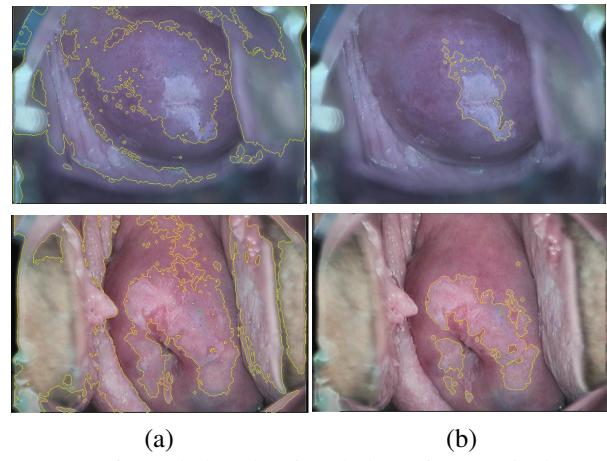


Figura 6. Efecto de la selección de la región cervical para la detección de la región acetoblanca mediante UMA: (a) Resultado sobre la imagen entera, (b) Resultado sobre la región cervical elegida

8.3 Detección de la región acetoblanca con distintos métodos de agrupamiento

A continuación se evalúa la detección la región acetoblanca usando distintos tipos de métodos de agrupamiento. Para esto se aplicó cada algoritmo a una misma imagen, sobre la misma ROI.

En la Figura 7 se puede observar la pequeña variación que existe de un método a otro en una misma imagen. Esto nos permite utilizar como criterio de selección el tiempo que se demora cada uno y en este caso el que menos tiempo tomó fue CustomGMM el cual estima los parámetros del modelo GMM mediante el algoritmo EM y usa *Mini Batch k-means* para inicializar los parámetros.

8.4 Multidetección de la región acetoblanca

En colposcopia, la diferenciación entre distintas intensidades de una misma región acetoblanca es también de gran importancia. Por ejemplo, la empresa DySIS⁵ comercializa sus colposcopios. Este software graba un video del proceso de cambio de color del epitelio cervical tras la aplicación del ácido acético y de esta forma se brinda un espectro de colores que indica cuáles zonas se tornaron más blancuzcas.

Con el objetivo de agrupar los píxeles dentro de la región acetoblanca se implementaron dos variantes: el agrupamiento con CustomGMM tomando un número determinado de grupos y la separación mediante UMA en el espacio de colores *Lab*. En la Figura 8 la escala de colores (del violeta al rojo) constituye una escala de intensidades de gris. Por ejemplo, en la Figura 8a se observa que la región central tiene un color amarillo que indica que esa zona tiene mayores intensidades de gris que el resto, i.e. absorbió más la solución de ácido acético lo que puede ser una señal de cáncer de cuello de útero. La multidetección descrita sugiere a los especialistas zonas

⁵Para más información puede consultarse el sitio oficial de la empresa: <http://dysismedical.com>

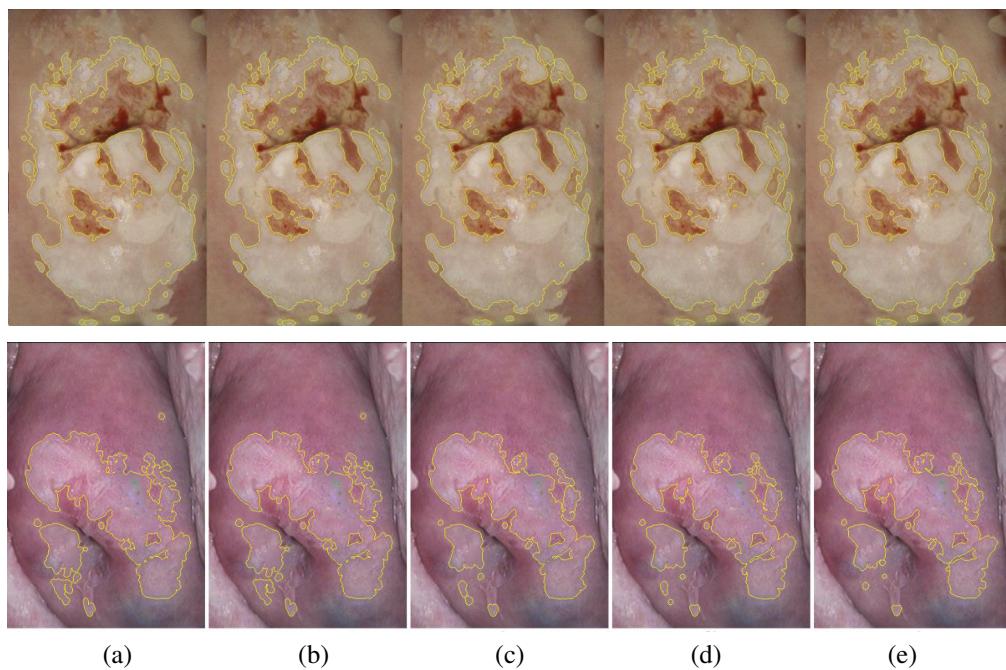


Figura 7. Resultados de aplicar los algoritmos de agrupamiento para detectar la región acetoblanca: (a) CustomGMM, (b) GMM, (c) VBGMM, (d) *k*–means y (e) Mini Batch *k*–means

en las que podrían realizarse biopsias.

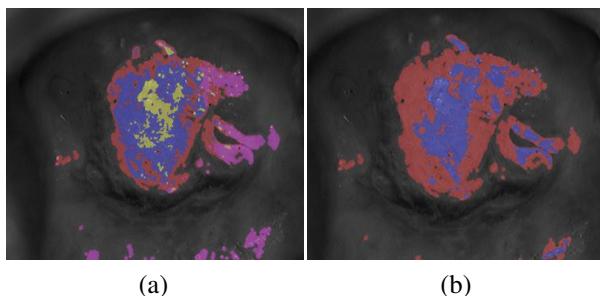


Figura 8. Resultados de la detección múltiple en la región acetoblanca: (a) Formando cuatro grupos mediante CustomGMM, (b) Formando dos grupos con UMA

8.5 Resultados de la evaluación cuantitativa

En el Cuadro 1 se presentan los resultados de la evaluación cuantitativa de los algoritmos para detectar la ROI y la región acetoblanca sobre las 40 imágenes. Estos valores indican una alta coincidencia entre la región detectada y la marcada por la especialista. Puede observarse que la detección de la ROI presenta, en promedio, el valor más bajo lo cual afecta la detección de la región acetoblanca pues los algoritmos de agrupamiento y UMA reciben como entrada la región cervical.

Detección de la ROI	84.5
Detección basada en agrupamiento	87.6
Detección basada en UMA	87.0

Cuadro 1. Promedio de la medida de calidad en la detección

En la Figura 9a se desglosan los valores de la medida de calidad para cada imagen y cada tarea de detección, alcanzándose valores mayores que 60 en la mayoría de las imágenes lo cual consideramos favorable. En la Figura 9b se observa que la detección por agrupamiento alcanza la mayor frecuencia de resultados con valores de la medida mayores que 90 (17) mientras que solo en ocho imágenes se obtuvo un valor mayor que 90 en la detección de la región cervical.

8.6 Resultados de la evaluación cualitativa

Con el fin de evaluar cualitativamente los resultados, se desarrolló además un software para la evaluación que permitió a la Dra. Santana evaluar la calidad de la identificación de la región acetoblanca detectada por los algoritmos propuestos. En esa evaluación se asignó un valor entre 0 y 100, siendo el valor 100 una segmentación muy buena o perfecta y el valor 0 una segmentación muy mala.

En la Figura 10 se muestran los resultados de dicha evaluación. Puede observarse que en la mayoría de las imágenes se logra detectar favorablemente la región acetoblanca alcanzándose 90 como valor máximo. Una de las imágenes recibió evaluación 0 para el algoritmo de agrupamiento mientras que obtuvo calificación satisfactoria con UMA (Ver Figura 10a). La Figura 10b muestra más claramente la tendencia favorable en las calificaciones de ambos algoritmos. Si bien en el intervalo [90, 100] ambos algoritmos presentaron un comportamiento similar, en el intervalo [80, 89] UMA mostró menos evaluaciones satisfactorias que el agrupamiento. Esto puede indicar una mayor susceptibilidad de UMA respecto a la detección previa de la región cervical.

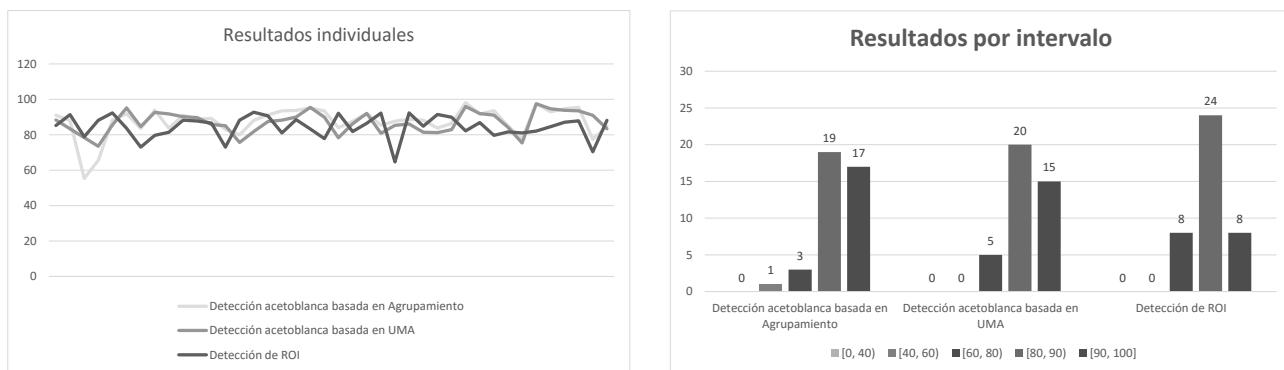


Figura 9. Resultados de la evaluación cuantitativa realizada para cada algoritmo de detección usado: (a) Calificaciones por imagen, (b) Cantidad de imágenes en cada intervalo de la medida de calidad

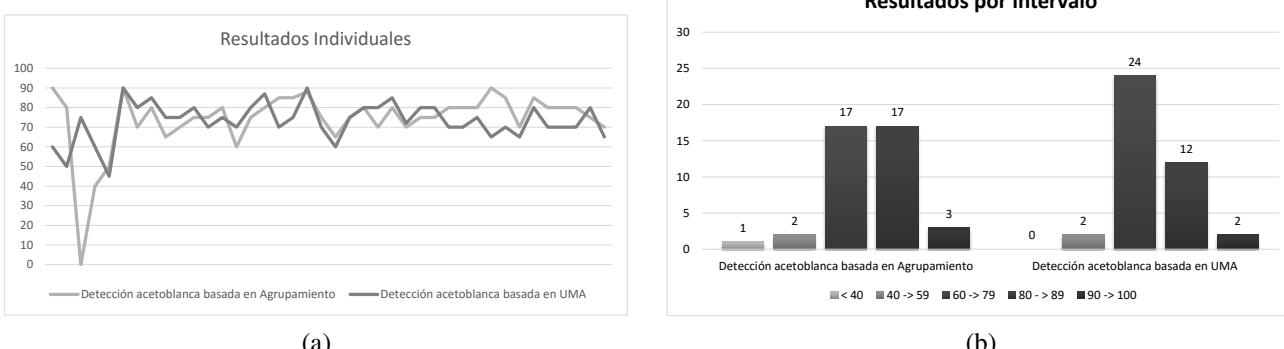


Figura 10. Resultados de la evaluación cualitativa realizada por la Dra. Santana para cada algoritmo de detección usado: (a) Calificaciones por imagen, (b) Cantidad de imágenes en cada intervalo de calificación

9. Conclusiones

En el trabajo se presenta una metodología para segmentar la región acetoblanca. Luego de una revisión de la literatura, se pudo constatar que el problema ha sido abordado en muy pocas ocasiones y de manera muy general. Se concluyó que era necesario el mejoramiento de la imagen y la detección de la región cervical o ROI como pasos previos a la detección de la región acetoblanca. También se constató que el uso de técnicas basadas en métodos de agrupamiento constituye un factor común. Se propuso un algoritmo para la detección de la ROI y dos procedimientos para la segmentación de la región acetoblanca. Estos métodos combinan las diferentes técnicas estudiadas con soluciones propias.

Se realizó una experimentación sobre todas las imágenes disponibles, se compararon cuatro algoritmos de agrupamiento y un método que combina umbralización con operaciones morfológicas. Los resultados reflejaron la importancia de la eliminación de regiones especulares características de las imágenes adquiridas.

Además, se propuso un algoritmo basado en agrupamiento para detectar diferentes niveles de intensidades de gris (multidetección) en la región acetoblanca. Estas zonas suelen ser un indicador de cáncer y pueden usarse como marcadores de biopsia que confirmen o no el diagnóstico.

Como parte del proceso de evaluación de la metodología se obtuvieron las *ground truth* para la muestra experimental y se propusieron y utilizaron dos medidas de calidad cuantitativa. Los resultados de estas medidas alcanzaron, en promedio, una efectividad del 87% en la detección de la región acetoblanca, validada por la evaluación cualitativa realizada por la Dra. Águeda Santana. El agrupamiento mediante el Modelo de Mezclas Gaussianas estimando parámetros con el algoritmo Esperanza-Maximización y *Mini-batch k-means* mostró los mejores resultados.

Referencias

- [1] E. C. Cruz. Conducta frente a la Neoplasia Intraepitelial Cervical (NIC). *Revista Cubana Obstetricia y Ginecología*, 24(3):156–60, 1998.
- [2] Ministerio de Salud Pública. Anuario Estadístico de Salud 2014, 2015.
- [3] J. Qiang, J. Engel, and E. Craine. Classifying cervix tissue patterns with texture analysis. *Pattern Recognition*, 33, 2000.
- [4] R. Reid and P. Scalzi. An improved colposcopic index for differentiating benign papillomaviral infections from

- high-grade cervical intraepithelial neoplasia. *International Journal of Gynecology & Obstetrics*, 24, 1986.
- [5] P. S. RamaPraba and H. Ranganathan. Colour histogram based colposcopy cervical image classification. In *International Conference on Advances in Computer and Information Technology*, 2013.
- [6] E. Rendon, A. Díaz, I. Abundez, and E. Gasca. Method to classify colposcopic images. *Recent Researches Communications Computers*, 2012.
- [7] M. Liang, G. Zheng, X. Huang, G. Milledge, and A. Tokuta. Identification of abnormal cervical regions from colposcopy image sequences. *Journal of WSCG*, 20, 2013.
- [8] A. Alush, H. Greenspan, and J. Goldberger. Lesion detection and segmentation in uterine cervix images using an arc-level MRF. In *IEEE International Symposium on Biomedical Imaging: From Nano to Macro*, pages 474–477. IEEE, 2009.
- [9] W. Li, J. Gu, D. Ferris, and A. Poirson. Automated image analysis of uterine cervical images. In *Medical Imaging*, pages 65142P–65142P. International Society for Optics and Photonics, 2007.
- [10] H. Lange. Automatic detection of multi-level acetowhite regions in rgb color images of the uterine cervix. In *Medical Imaging*, pages 1004–1017. International Society for Optics and Photonics, 2005.
- [11] S. Gordon, G. Zimmerman, and H. Greenspan. Image segmentation of uterine cervix images for indexing in pacs. In *17th IEEE Symposium on Computer-Based Medical Systems*, page 298. IEEE, 2004.
- [12] C. Ricardo. Empleo de filtros de la Morfología Matemática en imágenes de mamografías. Tesis de Diploma, Facultad de Matemática y Computación, Universidad de La Habana, Cuba. 2015.
- [13] O. Maimon and L. Rokach. *Data Mining and Knowledge Discovery Handbook*. Springer, 2005.
- [14] D. Sculley. Web-scale k -means clustering. In *Proceedings of the 19th International Conference on World Wide Web*, Raleigh, North Carolina, USA, 2010. ACM Press.
- [15] R. A. Redner and H. F. Walker. Mixture densities, maximum likelihood and the em algorithm. *SIAM review*, 26(2):195–239, 1984.
- [16] G. J. McLachlan and K. E. Basford. *Mixture models: Inference and applications to clustering*, volume 84. Marcel Dekker, 1988.
- [17] G. McLachlan and D. Peel. *Finite mixture models*. John Wiley & Sons, 2004.
- [18] L. Xu and M. I. Jordan. On convergence properties of the em algorithm for gaussian mixtures. *Neural computation*, 8(1):129–151, 1996.
- [19] G. McLachlan and T. Krishnan. *The EM algorithm and extensions*, volume 382. John Wiley & Sons, 2007.
- [20] D. M. Blei and M. I. Jordan. Variational inference for dirichlet process mixtures. *Bayesian analysis*, 1(1):121–143, 2006.
- [21] A. Palmer. Eliminación de regiones especulares en imágenes colposcópicas de cuello de útero. Tesis de Diploma, Facultad de Matemática y Computación, Universidad de La Habana, Cuba. 2015.
- [22] H. Greenspan, S. Gordon, G. Zimmerman, S. Lotenberg, J. Jeronimo, S. Antani, and R. Long. Automatic detection of anatomical landmarks in uterine cervix images. *IEEE Transactions on Medical Imaging*, 28(3):454–468, 2009.
- [23] S. Gordon, G. Zimmerman, R. Long, S. Antani, J. Jeronimo, and H. Greenspan. Content analysis of uterine cervix images: Initial steps towards content based indexing and retrieval of cervigrams. In *Medical Imaging*. International Society for Optics and Photonics, 2006.
- [24] G. Zimmerman, S. Gordon, and H. Greenspan. Automatic landmark detection in uterine cervix images for indexing in a content-retrieval system. In *3rd IEEE International Symposium on Biomedical Imaging: Nano to Macro*, pages 1348–1351. IEEE, 2006.
- [25] A. Das, A. Kar, and D. Bhattacharyya. Elimination of specular reflection and identification of ROI: The first step in automated detection of cervical cancer using digital colposcopy. In *2011 IEEE International Conference on Imaging Systems and Techniques*, pages 237–241. IEEE, 2011.
- [26] B. B. Sánchez. Desarrollo de herramientas para la detección de regiones de interés en termogramas de mamas. Tesis de Diploma, Facultad de Matemática y Computación, Universidad de La Habana, Cuba. 2015.
- [27] J. Del Risco. Transformada de watershed y detección automática de marcadores: una propuesta para segmentación de imágenes. Tesis de Diploma, Facultad de Matemática y Computación, Universidad de La Habana, Cuba. 2013.
- [28] Y. Srinivasan, S. Yang, B. Nutter, S. Mitra, B. Phillips, and R. Long. Challenges in automated detection of cervical intraepithelial neoplasia. In *Medical Imaging*, pages 65140F–65140F. International Society for Optics and Photonics, 2007.

- [29] N. Otsu. A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1):62–66, 1979.
- [30] G. van Rossum. Python Tutorial. Technical Report CS-R9526, Centrum voor Wiskunde & Informatica (CWI), Amsterdam, 1995.
- [31] S. van der Walt, S. C. Colbert, and G. Varoquaux. The NumPy Array: A Structure for Efficient Numerical Computation. *Computing in Science & Engineering*, 13(2):22–30, 2011.
- [32] E. Jones, T. Oliphant, and P. Peterson. Scipy: Open Source Scientific Tools for Python. 2014.
- [33] J. D. Hunter. Matplotlib: A 2D Graphics Environment. *Computing in Science and Engineering*, 9(3):90–95, 2007.
- [34] S. van der Walt, J. L. Schönberger, J. Nunez-Iglesias, F. Boulogne, J. D. Warner, N. Yager, E. Gouillart, T. Yu, and The scikit-image contributors. scikit-image: Image Processing in Python. *PeerJ*, 2:453, 2014.
- [35] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [36] G. R. Bradski. The OpenCV Library. *Dr. Dobb's Journal of Software Tools*, 2000.